

# Brown Bag Lunch #1

Introduction à Kafka-Streams

# Sommaire

# Sommaire

- Kafka-streams, c'est quoi ?

# Sommaire

- Kafka-streams, c'est quoi ?
- Exemple #1 : to-uppercase

# Sommaire

- Kafka-streams, c'est quoi ?
- Exemple #1 : to-uppercase
- Exemple #2 : word-split

# Sommaire

- Kafka-streams, c'est quoi ?
- Exemple #1 : to-uppercase
- Exemple #2 : word-split
- Exemple #3 : wordcount

# Sommaire

- Kafka-streams, c'est quoi ?
- Exemple #1 : to-uppercase
- Exemple #2 : word-split
- Exemple #3 : wordcount
- Bonus #1: windowing

# Sommaire

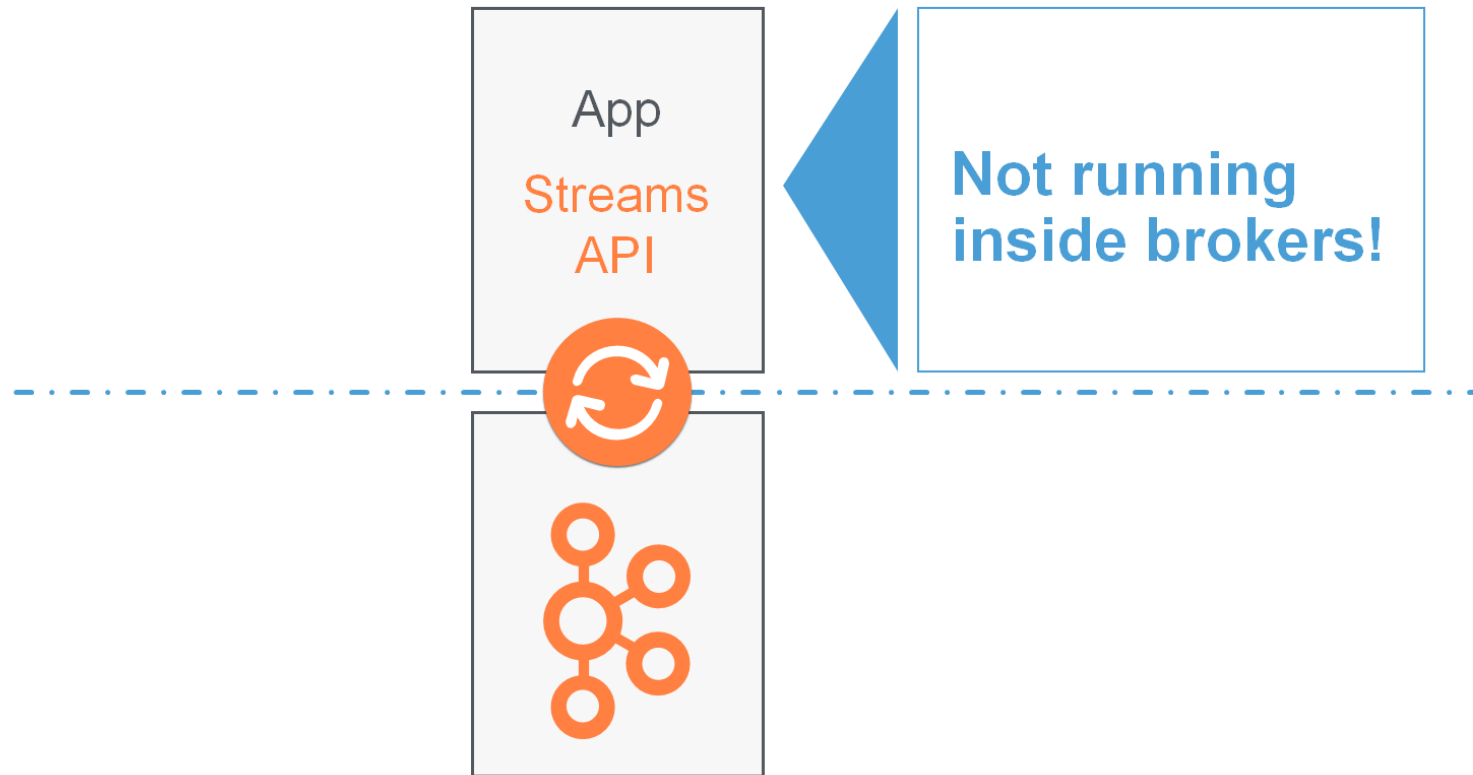
- Kafka-streams, c'est quoi ?
- Exemple #1 : to-uppercase
- Exemple #2 : word-split
- Exemple #3 : wordcount
- Bonus #1: windowing
- Bonus #2: joins – streams & Ktable



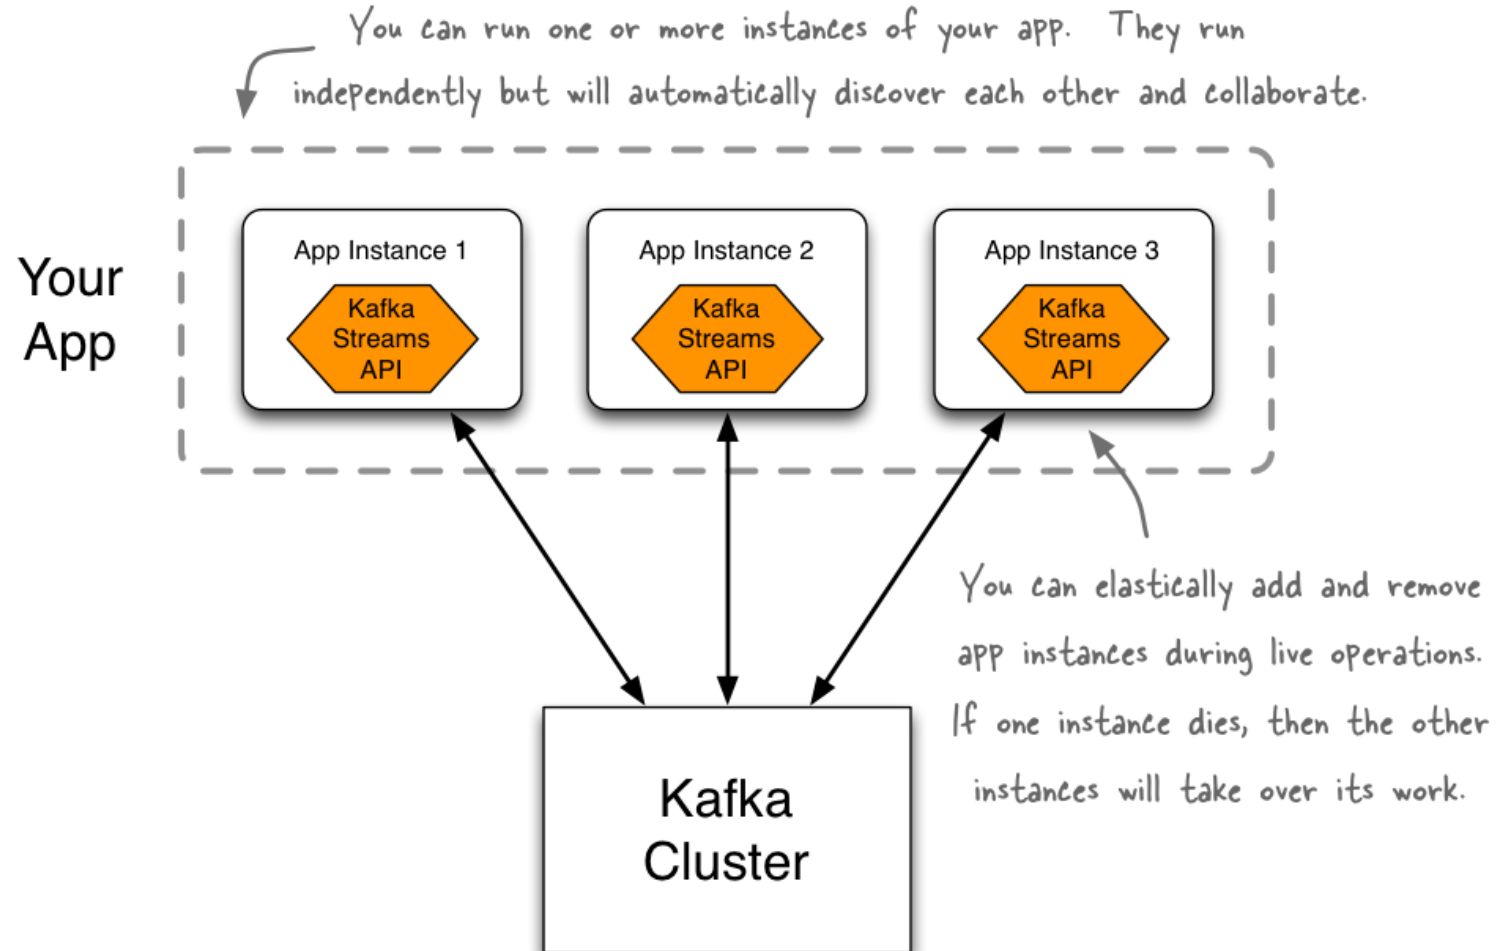
# Sommaire

- Kafka-streams, c'est quoi ?
- Exemple #1 : to-uppercase
- Exemple #2 : word-split
- Exemple #3 : wordcount
- Bonus #1: windowing
- Bonus #2: joins – streams & Ktable
- Conclusions ?


# Kafka-streams, c'est quoi ? – Vue d'avion



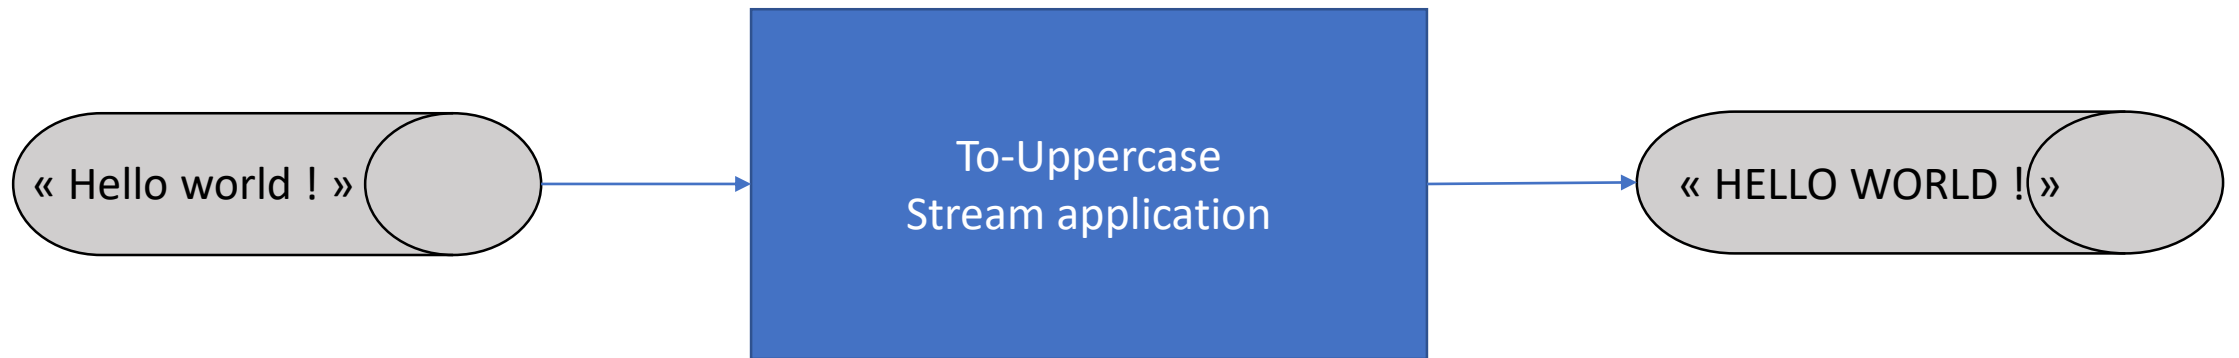
# Kafka-streams, c'est quoi ? – Vue d'avion



# Kafka-streams, c'est quoi ? – quelques concepts



# Exemple #1 : to-uppercase




# Exemple #1 : to-uppercase

- Codons !

# Exemple #1 : to-uppercase

- Codons !
- Checklist
  - Créer les topics manuellement avant
  - Lister et décrire les consumer group une fois l'appli lancée et arrêtée
  - Lister les topics
  - Tests unitaires
  - Implémentation via la DSL fonctionnelle de « haut niveau »
  - Implémentation via l'API impérative de « bas niveau »
  - Vue « Tasks et partitions » de l'exemple
    - Augmenter le nombre de partitions et constater l'augmentation du nombre de tasks
  - Step-by-step de l'exemple « architecture » de la doc de Confluent

## Exemple #2 : word-split

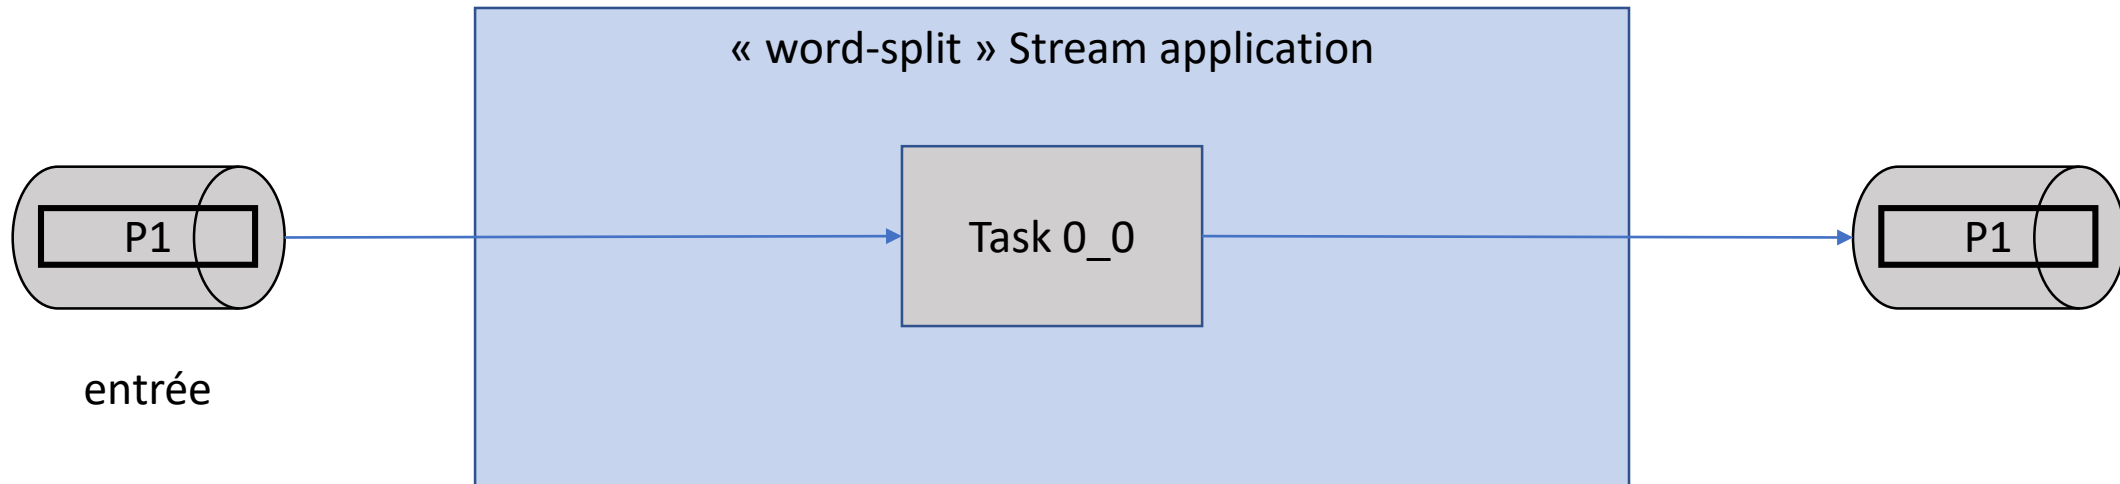




## Exemple #2 : word-split

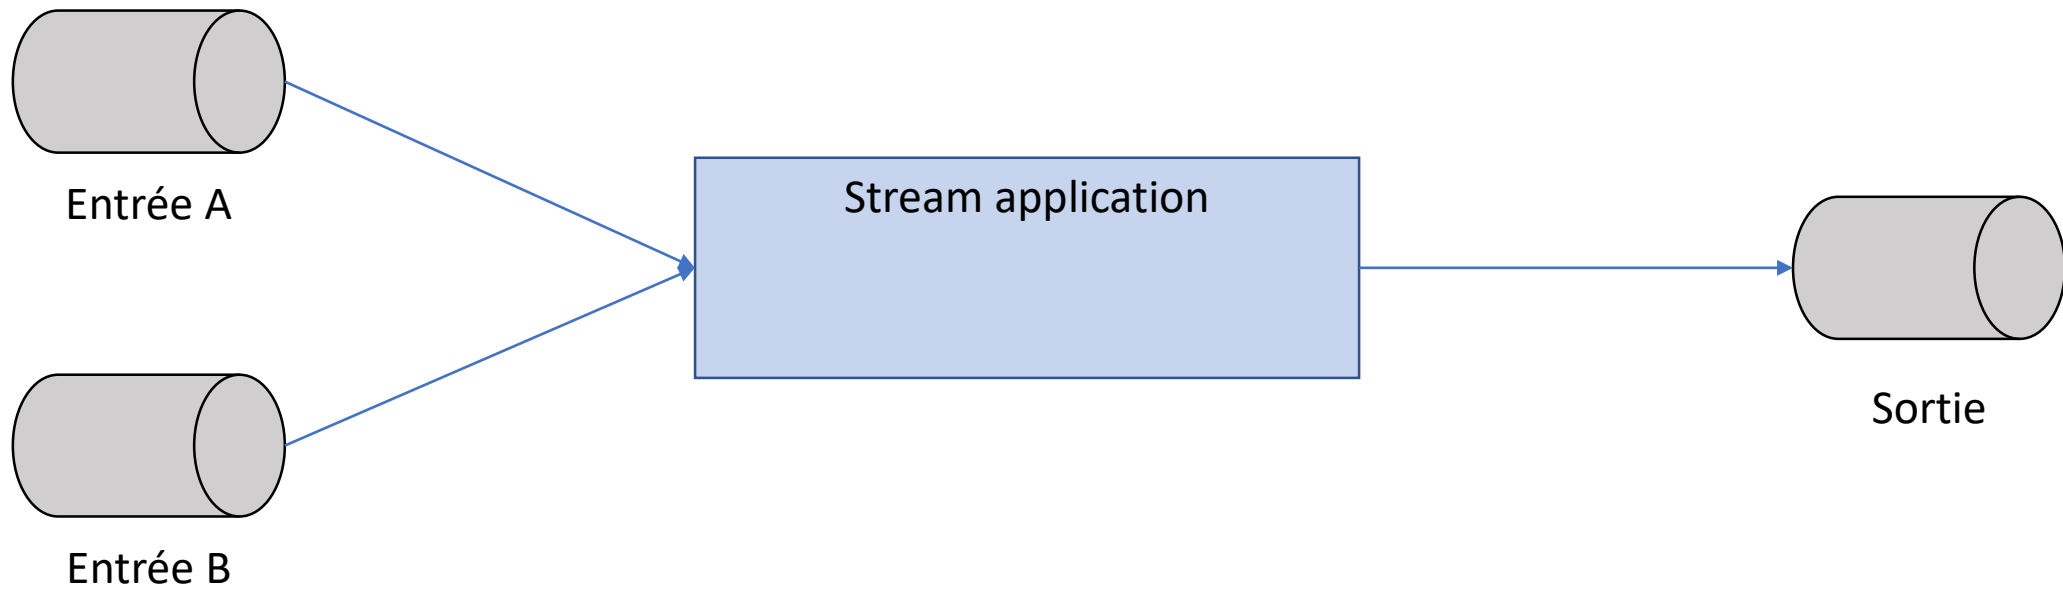
- Codons !

# Exemple #2 : word-split

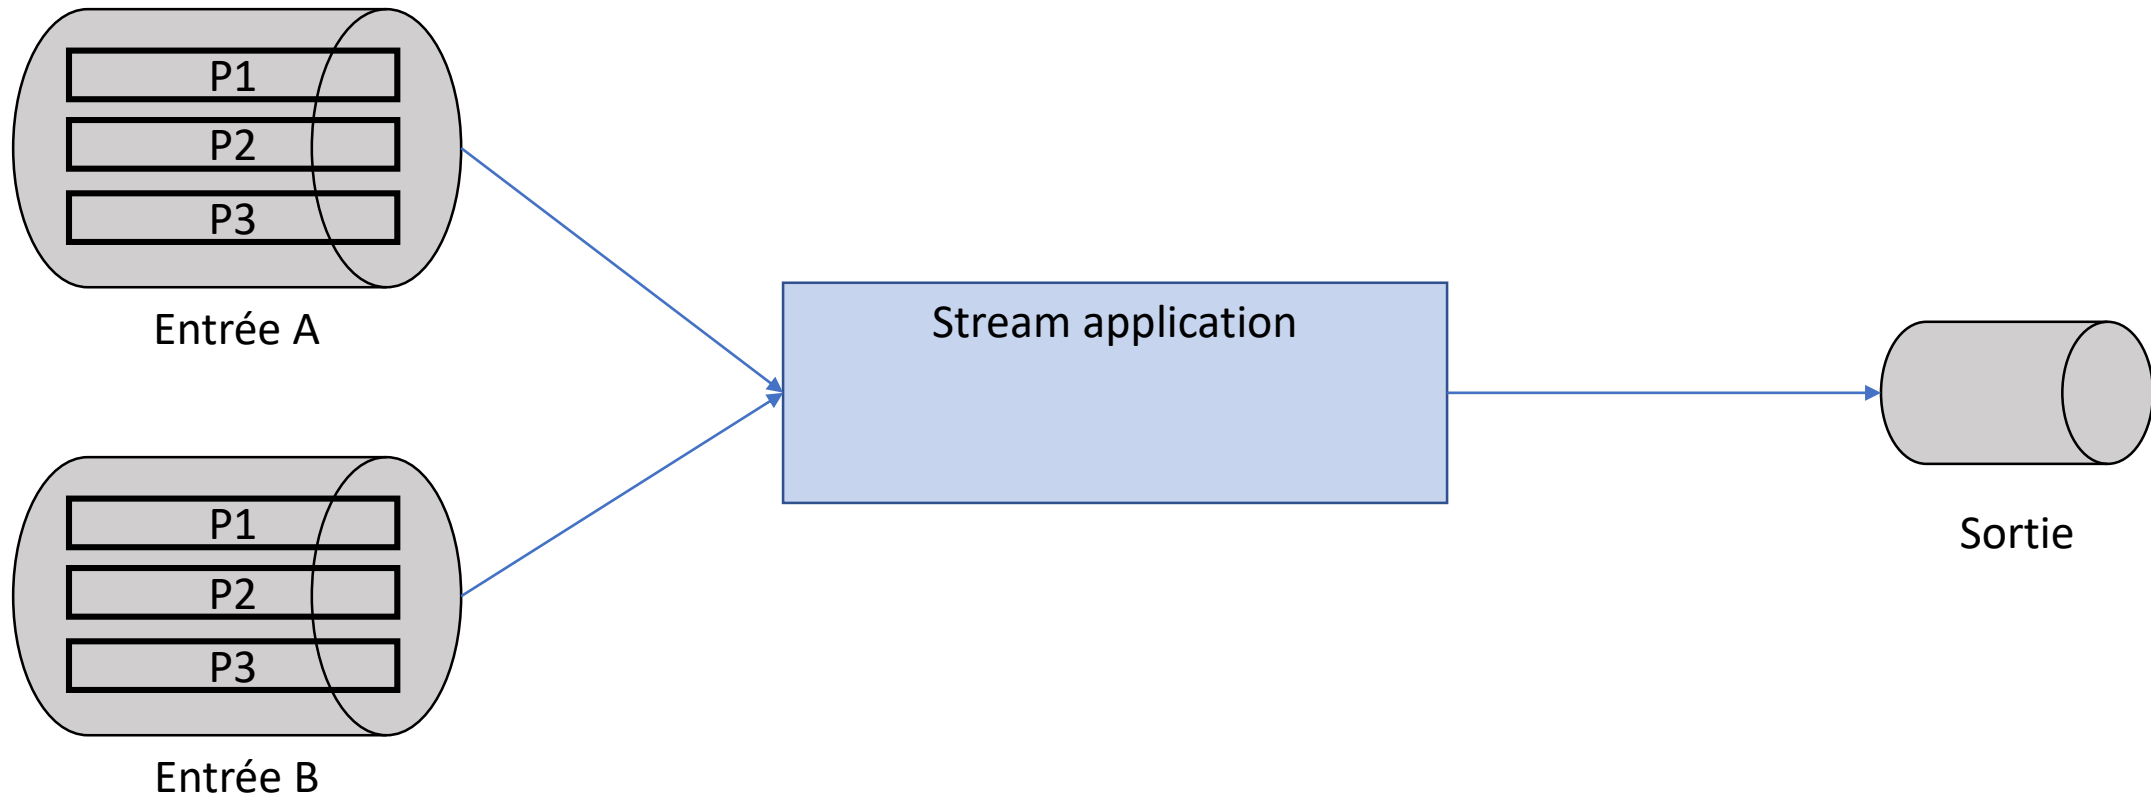


# Interlude: les « tasks » et leur affectation

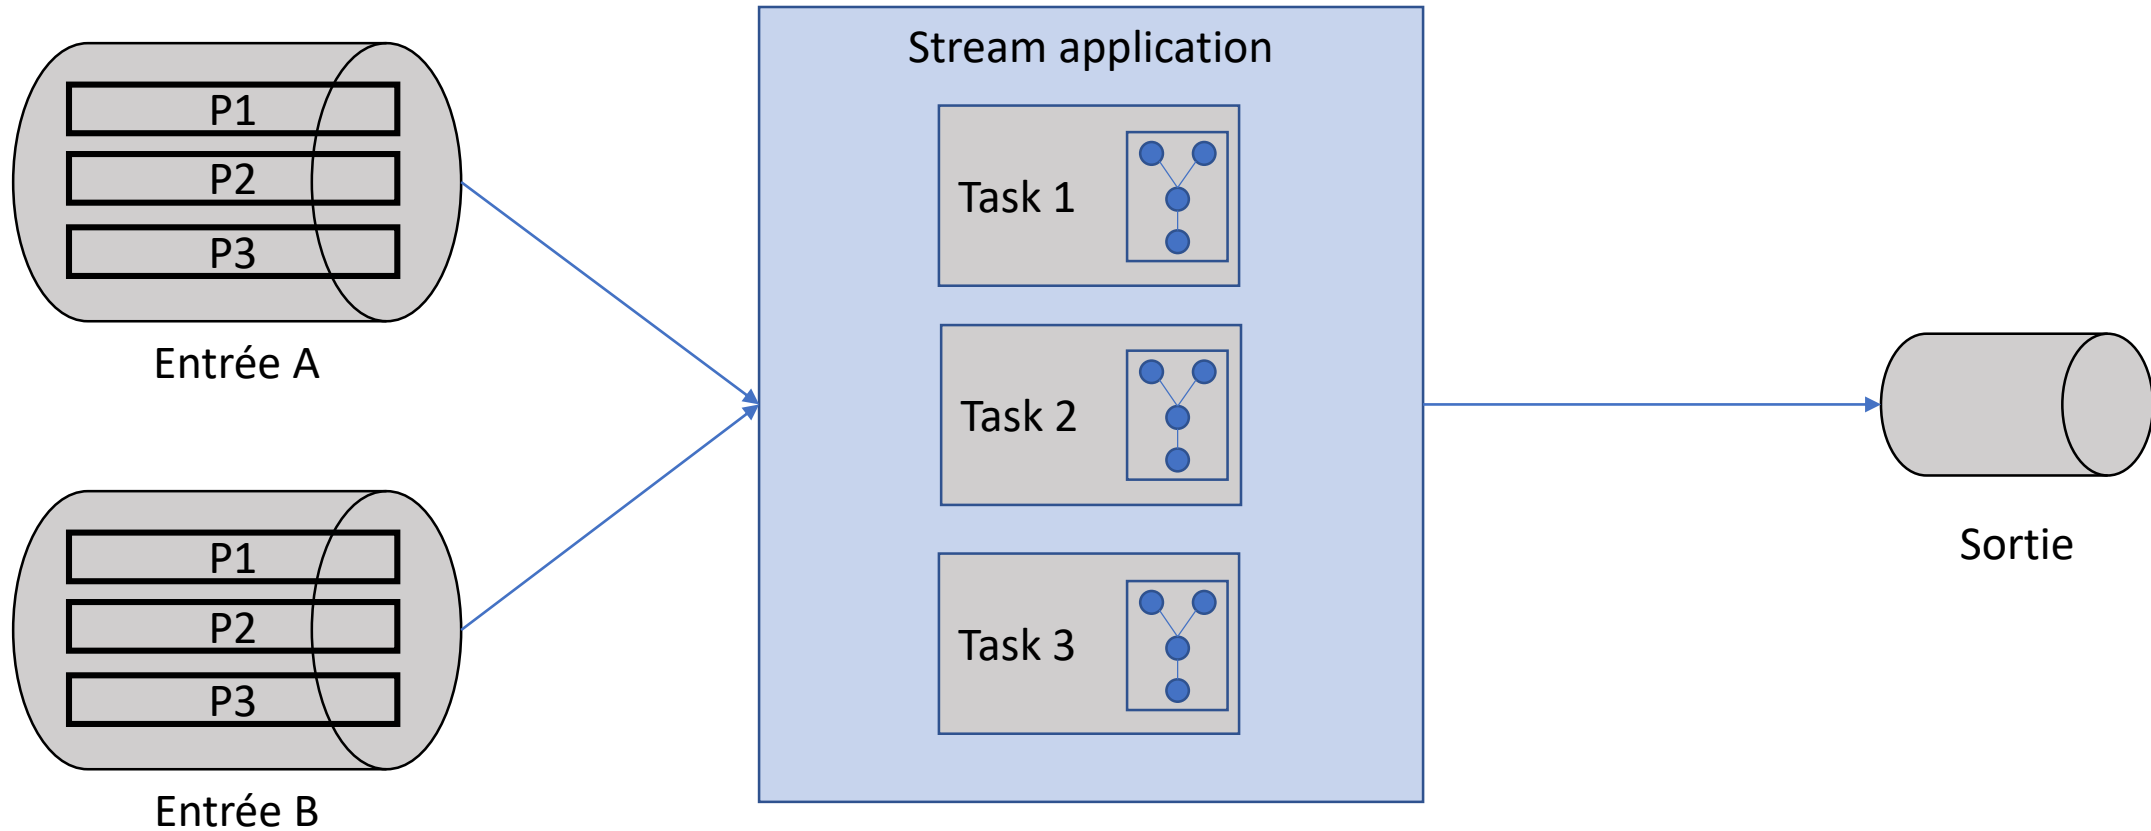
# Interlude: les « tasks » et leur affectation




# Interlude: les « tasks » et leur affectation




# Interlude: les « tasks » et leur affectation



# Interlude: les « tasks » et leur affectation




# Interlude: les « tasks » et leur affectation







# Interlude: les « tasks » et leur affectation



# Interlude: les « tasks » et leur affectation




# Interlude: les « tasks » et leur affectation



# Exemple #2 : word-split

- Codons !
- Checklist
  - Créer les topics manuellement avant
  - Tests unitaires
  - Implémentation via la DSL fonctionnelle de « haut niveau »
  - Implémentation via l'API impérative de « bas niveau »
  - Vue « tasks et partition » très rapidement

# Exemple #3 : wordcount



Exemple #3 : wordcount – illustration de l'algo

# Exemple #3 : wordcount – illustration de l'algo

<  $\emptyset$ , première ligne >  
<  $\emptyset$ , deuxième ligne >  
<  $\emptyset$ , troisième ligne >

# Exemple #3 : wordcount – illustration de l'algo

<  $\emptyset$ , première ligne >

<  $\emptyset$ , deuxième ligne >

<  $\emptyset$ , troisième ligne > 

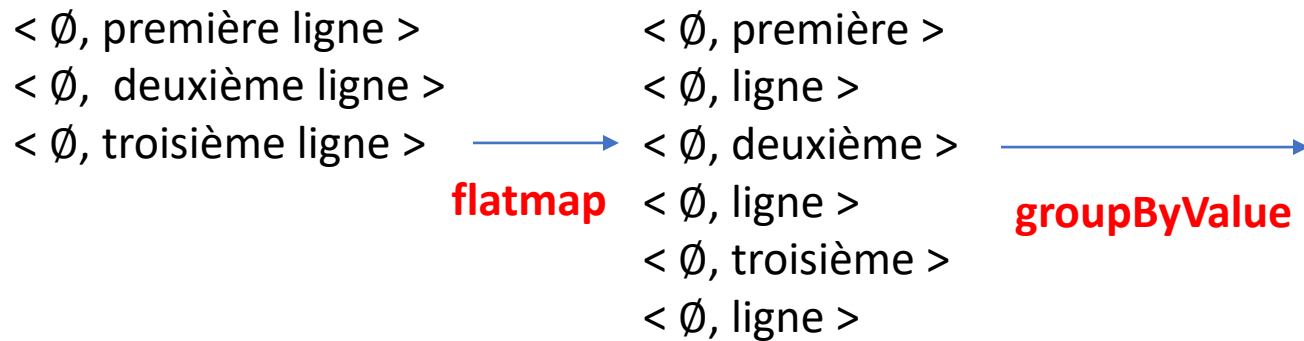
**flatMap**



# Exemple #3 : wordcount – illustration de l'algo

< ∅, première ligne >		< ∅, première >
< ∅, deuxième ligne >		< ∅, ligne >
< ∅, troisième ligne >	→	< ∅, deuxième >
	<b>flatMap</b>	< ∅, ligne >
		< ∅, troisième >
		< ∅, ligne >

# Exemple #3 : wordcount – illustration de l’algo



# Exemple #3 : wordcount – illustration de l’algo

< Ø, première ligne >  
< Ø, deuxième ligne >  
< Ø, troisième ligne >

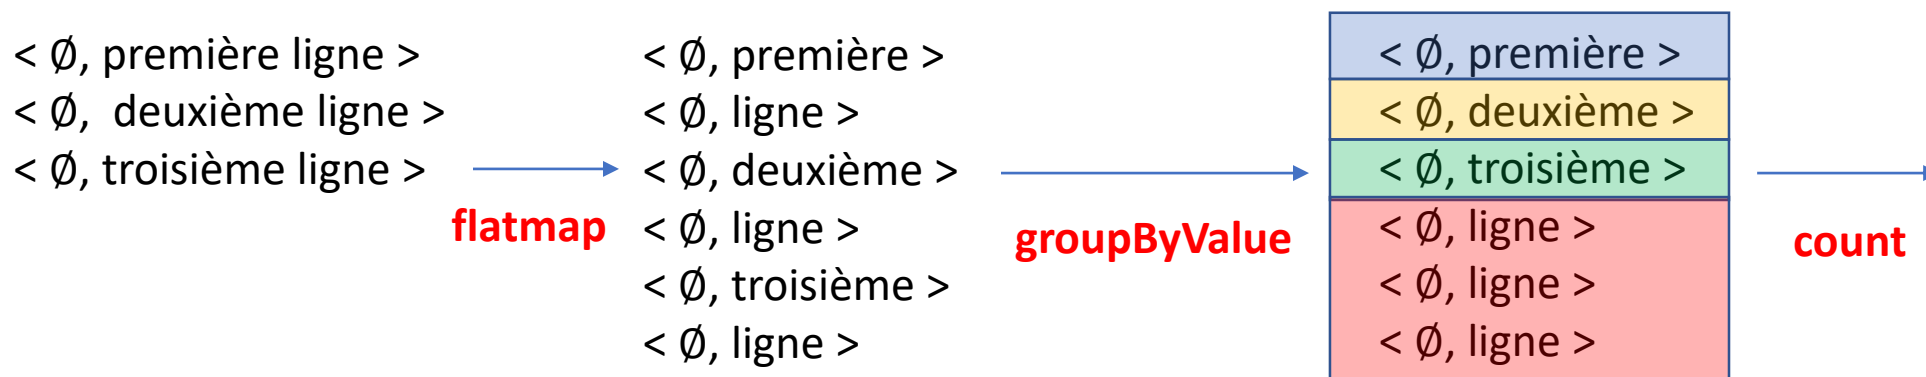
**flatMap**

< Ø, première >  
< Ø, ligne >  
< Ø, deuxième >  
< Ø, ligne >  
< Ø, troisième >  
< Ø, ligne >


**groupByKey**

< Ø, première >
< Ø, deuxième >
< Ø, troisième >
< Ø, ligne >
< Ø, ligne >
< Ø, ligne >


# Exemple #3 : wordcount – illustration de l’algo



# Exemple #3 : wordcount – illustration de l’algo



# Exemple #3 : wordcount – illustration de l’algo



L’intuition de l’analogie avec l’algo MapReduce était en fait tout à fait correcte, l’étude du détail de l’implémentation et de la variante « group by key » le révélera encore plus.

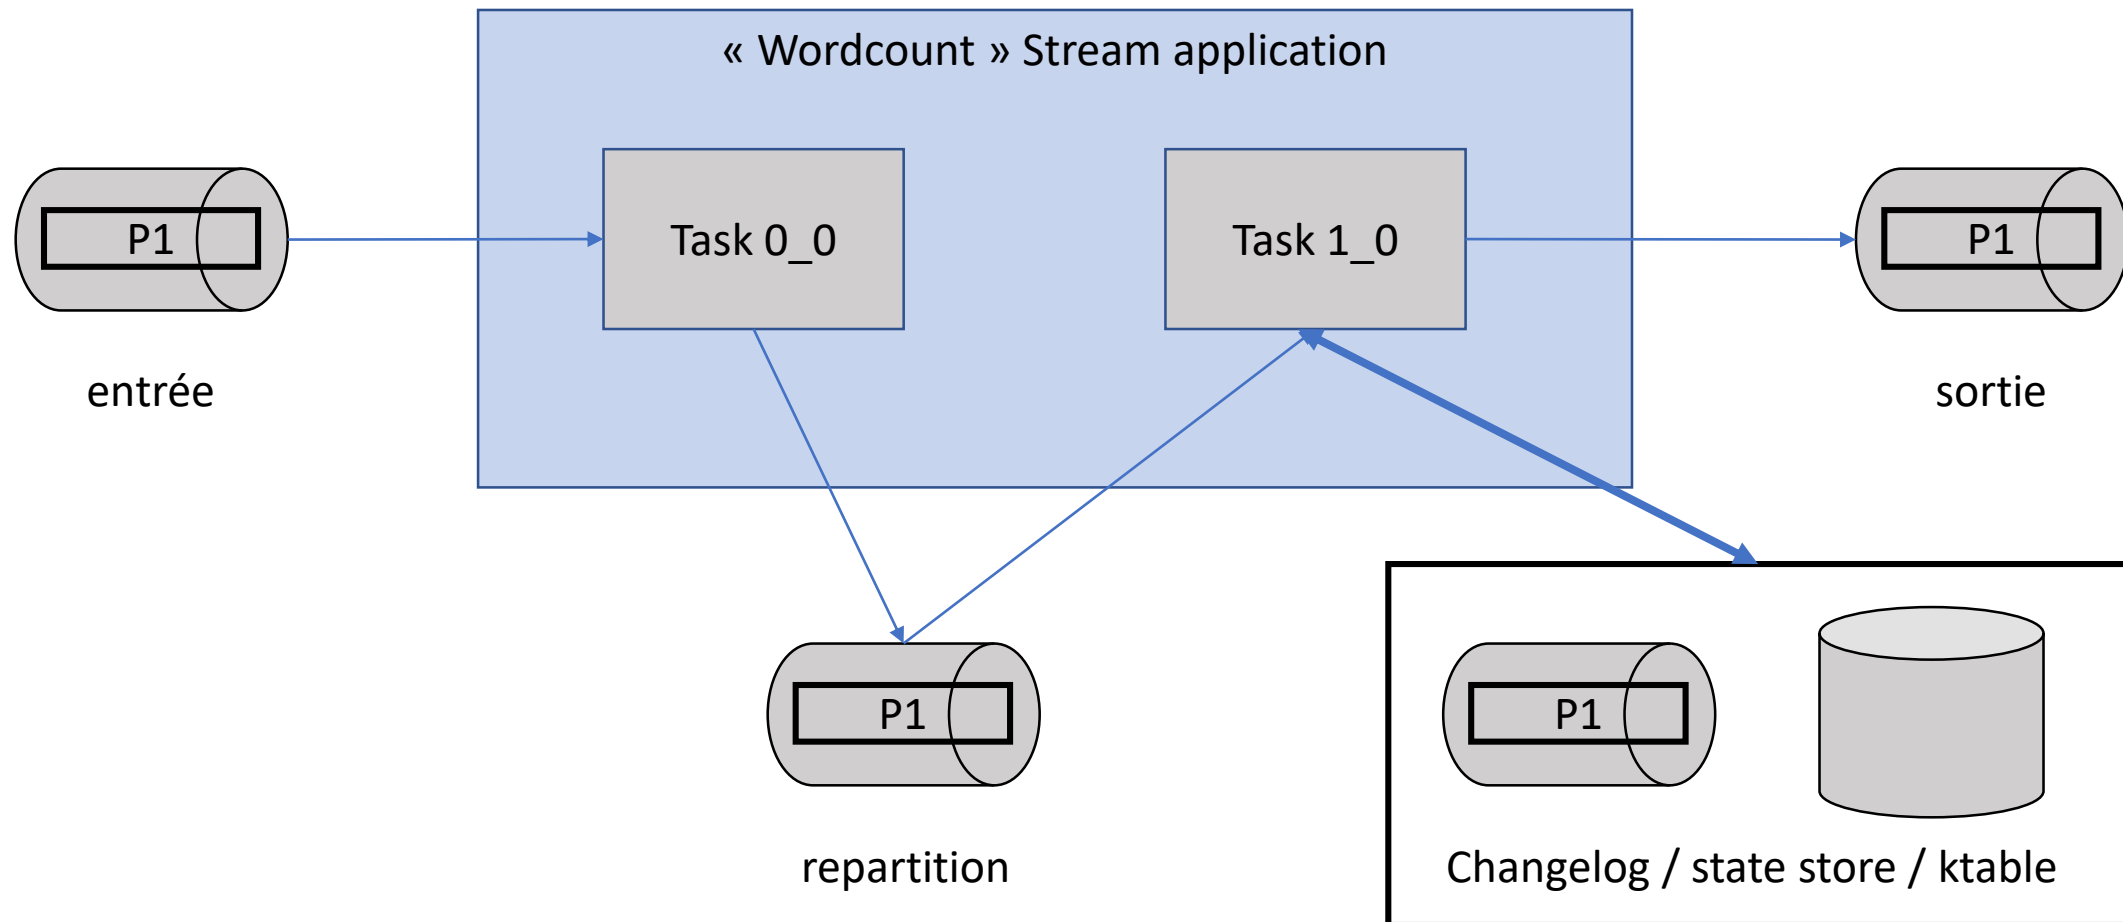
Exemple #3 : wordcount – Codons !

# Exemple #3 : wordcount – Codons !

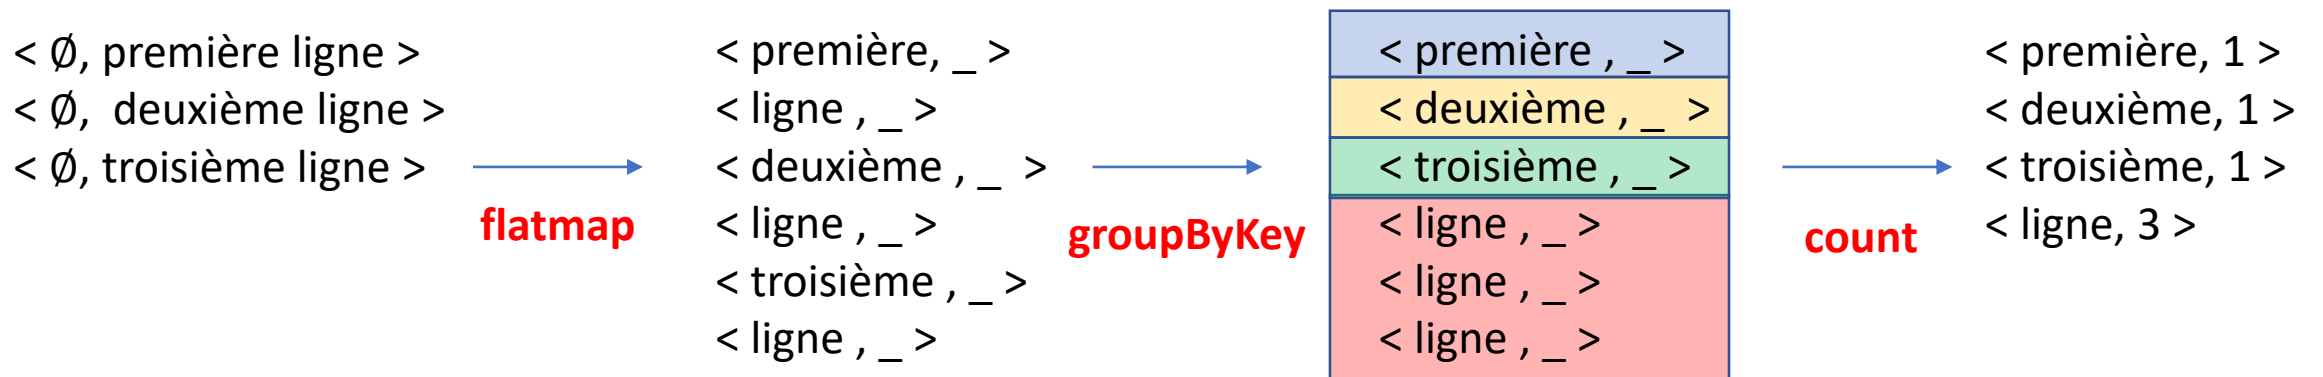
- Checklist
  - Créer les topics manuellement avant
  - Tests unitaires ?
  - groupByValue
  - Lister les topics créés, focus sur le topic « changelog »
    - State store, dualité Ktable / Kstream, Fault Tolerance
    - « repartition » vide pour le moment, on le verra dans l'exemple suivant



# Exemple #3 : wordcount



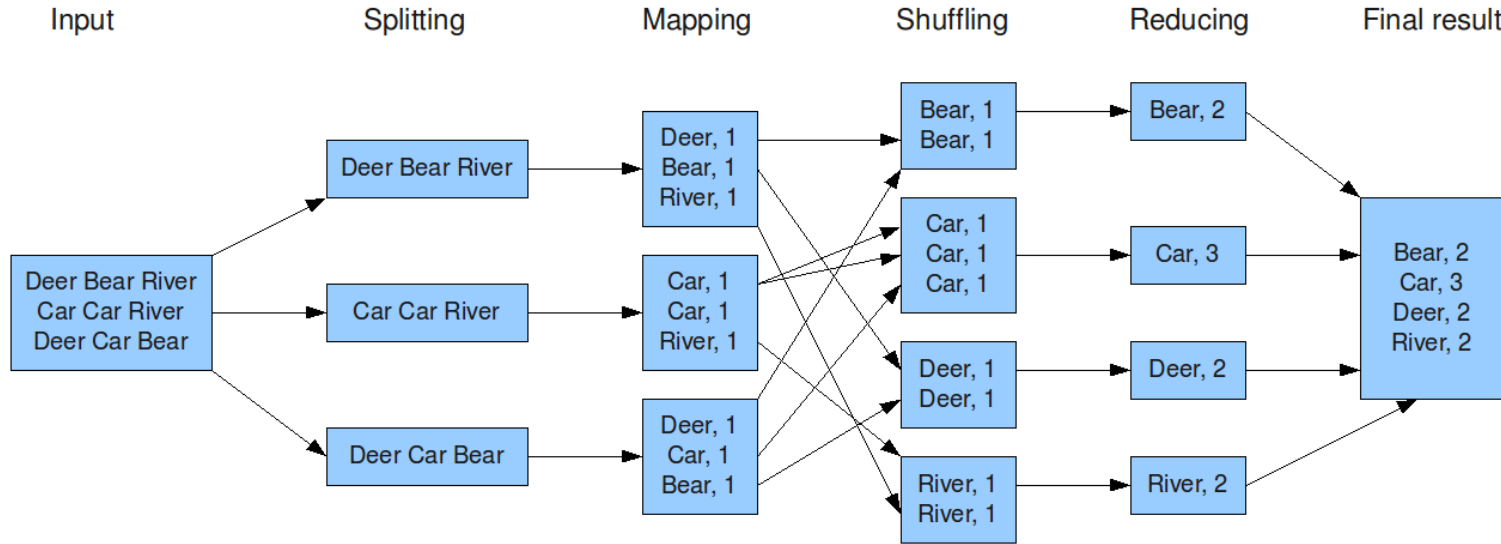
# Exemple #3 : wordcount – illustration de la variante « group by key »



Exemple #3 : wordcount – illustration de la variante « group by key » – codons

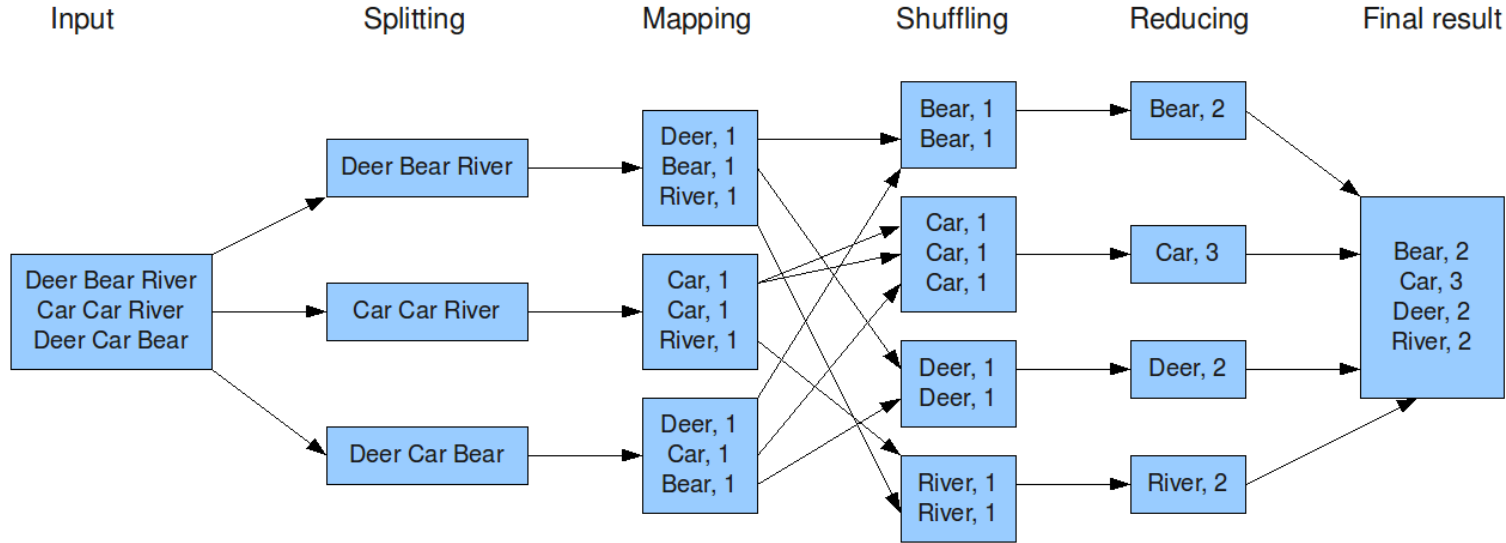
# Exemple #3 : wordcount – analogie avec mapreduce

The overall MapReduce word count process

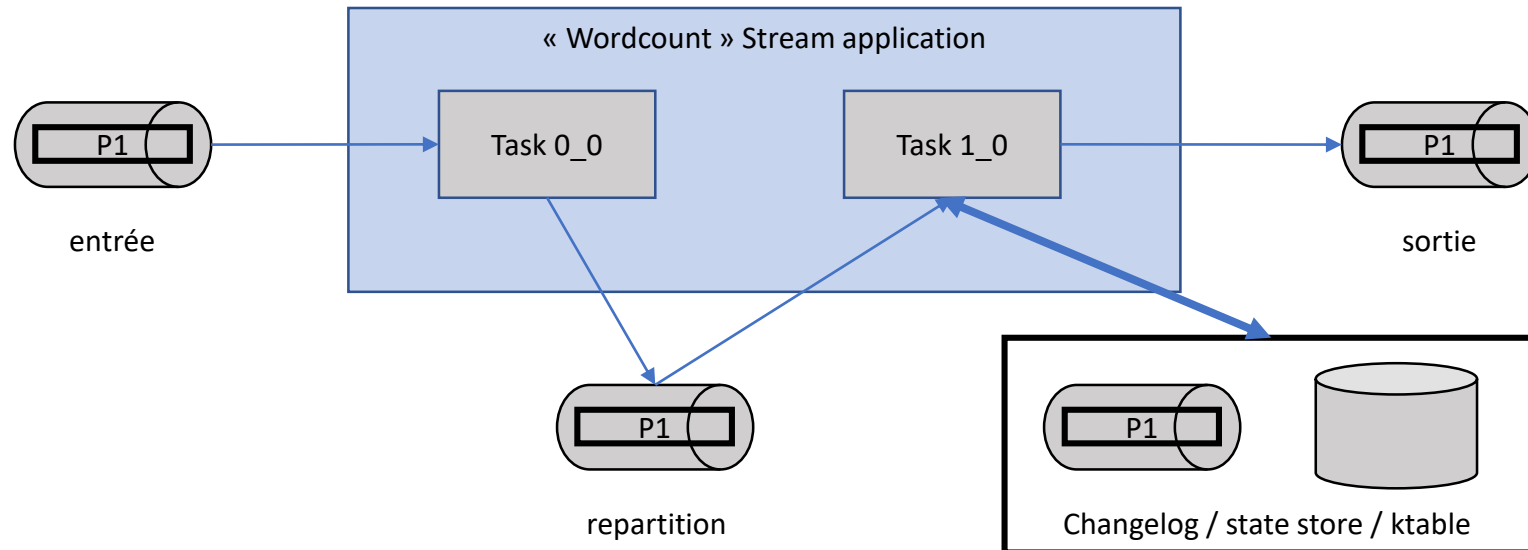


# Exemple #3 : wordcount – analogie avec mapreduce

The overall MapReduce word count process



```
public static Topology getTopology() {  
    StreamsBuilder builder = new StreamsBuilder();  
    builder.<String, String>stream(INPUT_TOPIC)  
        .flatMapValues(value -> Arrays.asList(value.split("\\W+")))  
        .map((key, value) -> new KeyValue<>(value, 1))  
        .groupByKey(Grouped.valueSerde(Serdes.Integer()))  
        .count();  
    return builder.build();  
}
```



# Exemple #3 : wordcount – Interactive queries

- Codons !
- Checklist
  - groupByKey
    - serdes error
    - serdes correction
  - Interactive queries
  - State stores et dualité kstream / ktable
  - Vue « tasks » des différentes implémentations

# Bonus #1: windowing - Sommaire


- Un premier exemple jouet
  - Sliding window
- Les différents types de windowing

# Bonus #1: windowing – exemple jouet – Sliding window







## Bonus #1: windowing – exemple jouet – Sliding window




## Bonus #1: windowing – exemple jouet – Sliding window



# Bonus #1: windowing – exemple jouet – Sliding window




# Bonus #1: windowing – exemple jouet – Sliding window




```
public static Topology getTopology() {
    StreamsBuilder builder = new StreamsBuilder();
    builder.<String, Float>stream(INPUT_TOPIC)
        .groupByKey()
        .windowedBy(SlidingWindows.withTimeDifferenceAndGrace(Duration.ofMillis(WINDOW_SIZE_MILLIS), Duration.ofMinutes(1)))
        .reduce(Float::sum, Materialized.as(STORE_NAME))
        .toStream()
        .to(OUTPUT_TOPIC, Produced.keySerde(WindowedSerdes.timeWindowedSerdeFrom(String.class, WINDOW_SIZE_MILLIS)));
    return builder.build();
}
```


# Bonus #1: windowing – exemple jouet – Sliding window




# Bonus #1: windowing – exemple jouet – Sliding window



# Bonus #1: windowing – exemple jouet – Sliding window

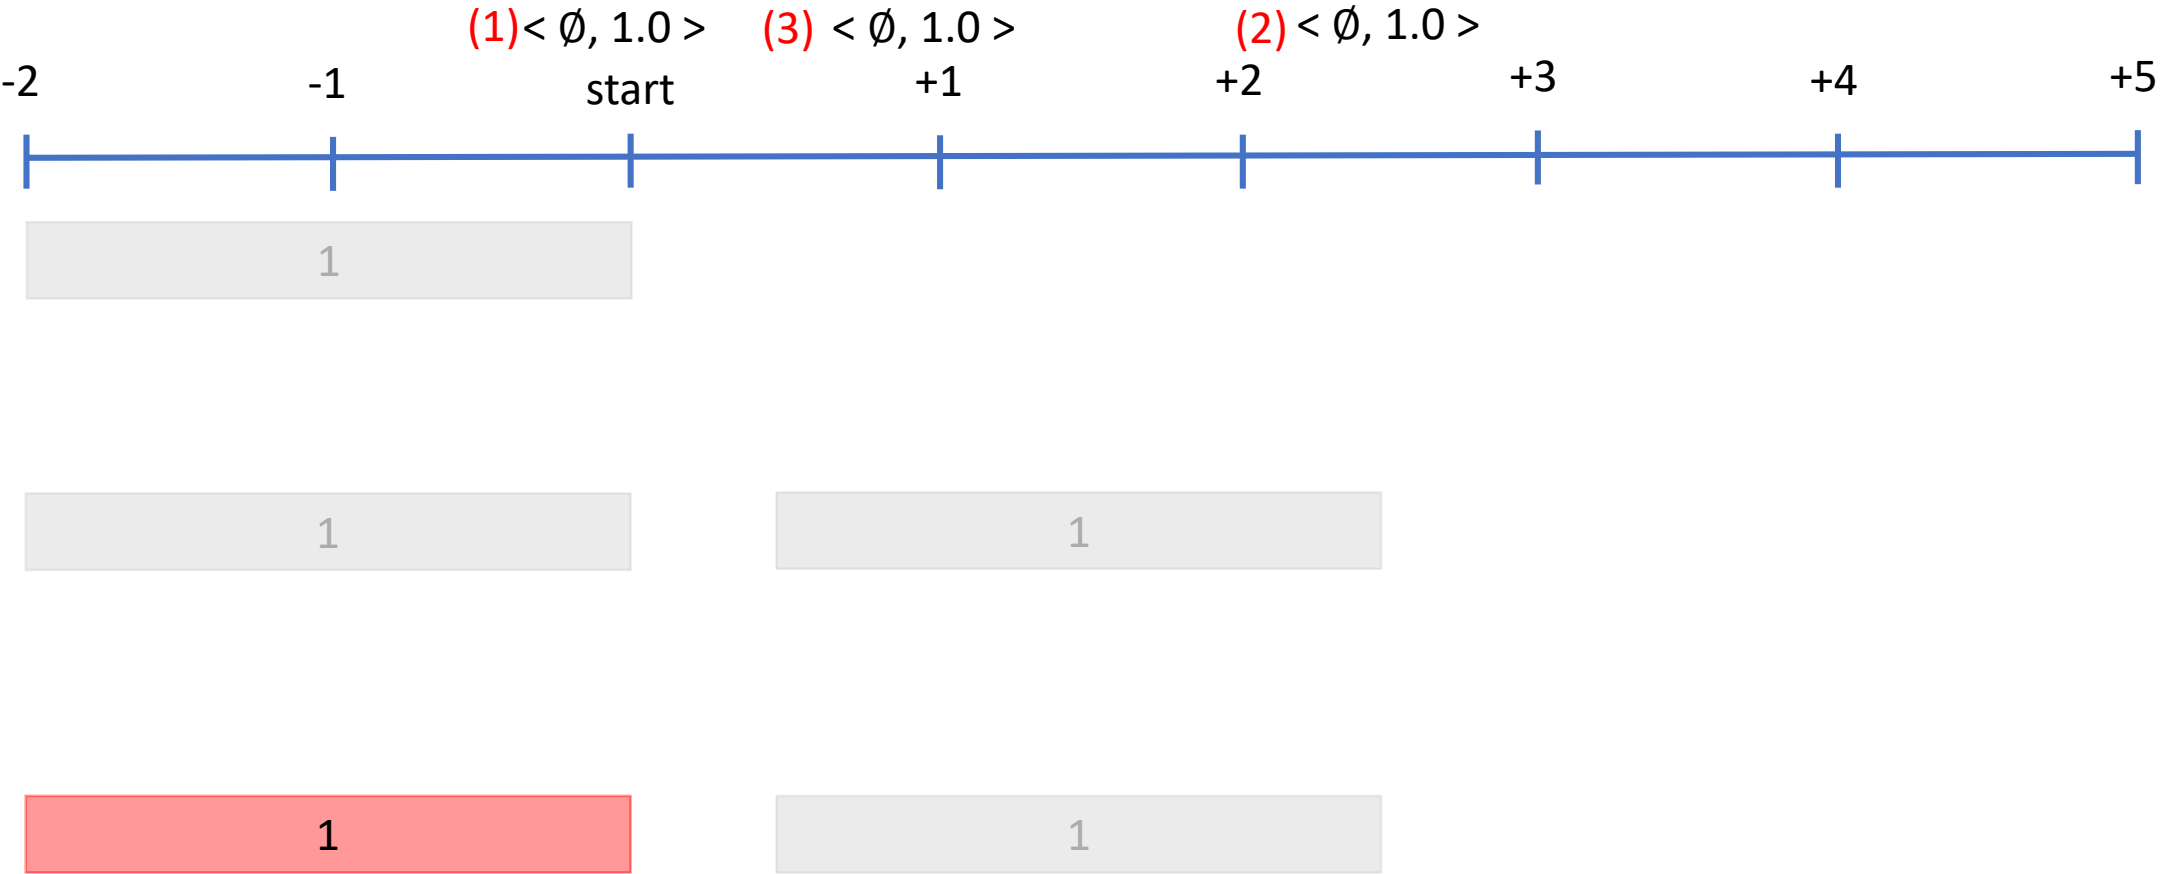


# Bonus #1: windowing – exemple jouet – Sliding window

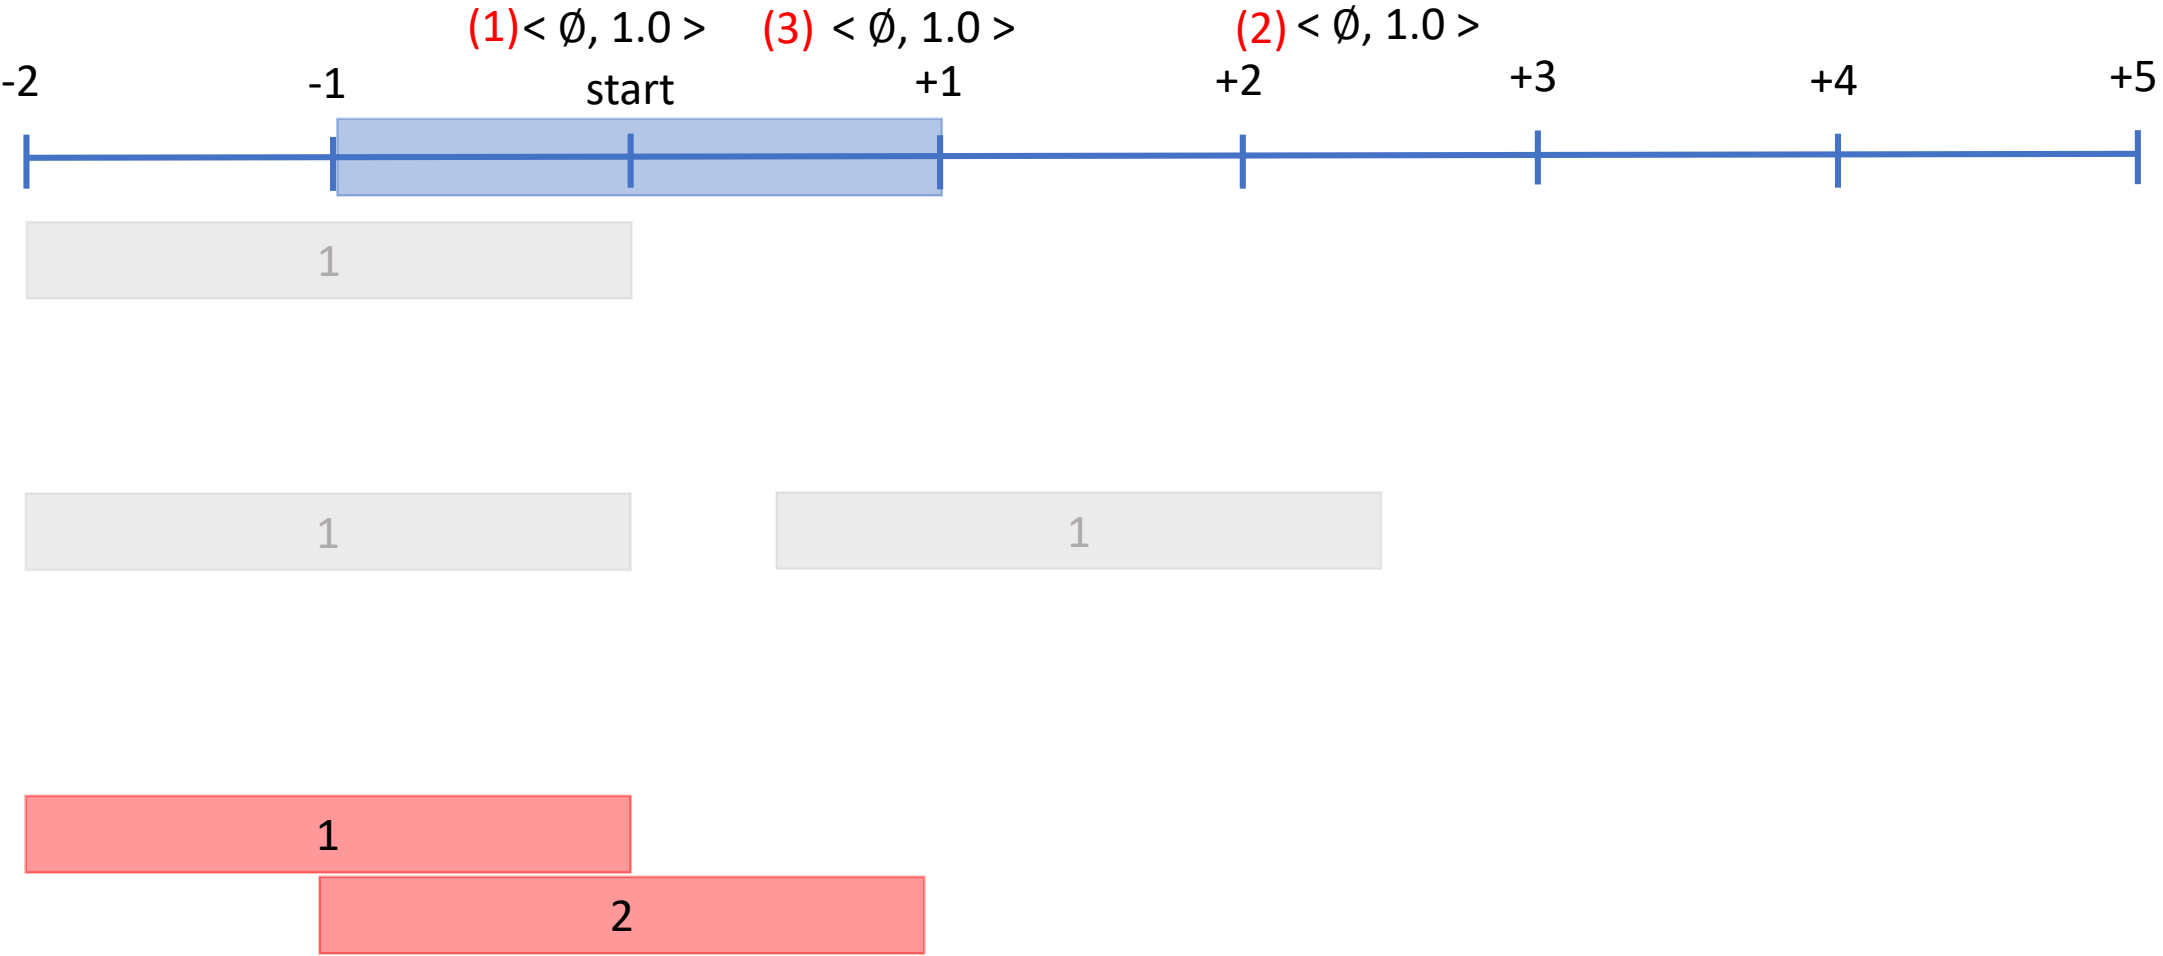





# Bonus #1: windowing – exemple jouet – Sliding window




# Bonus #1: windowing – exemple jouet – Sliding window



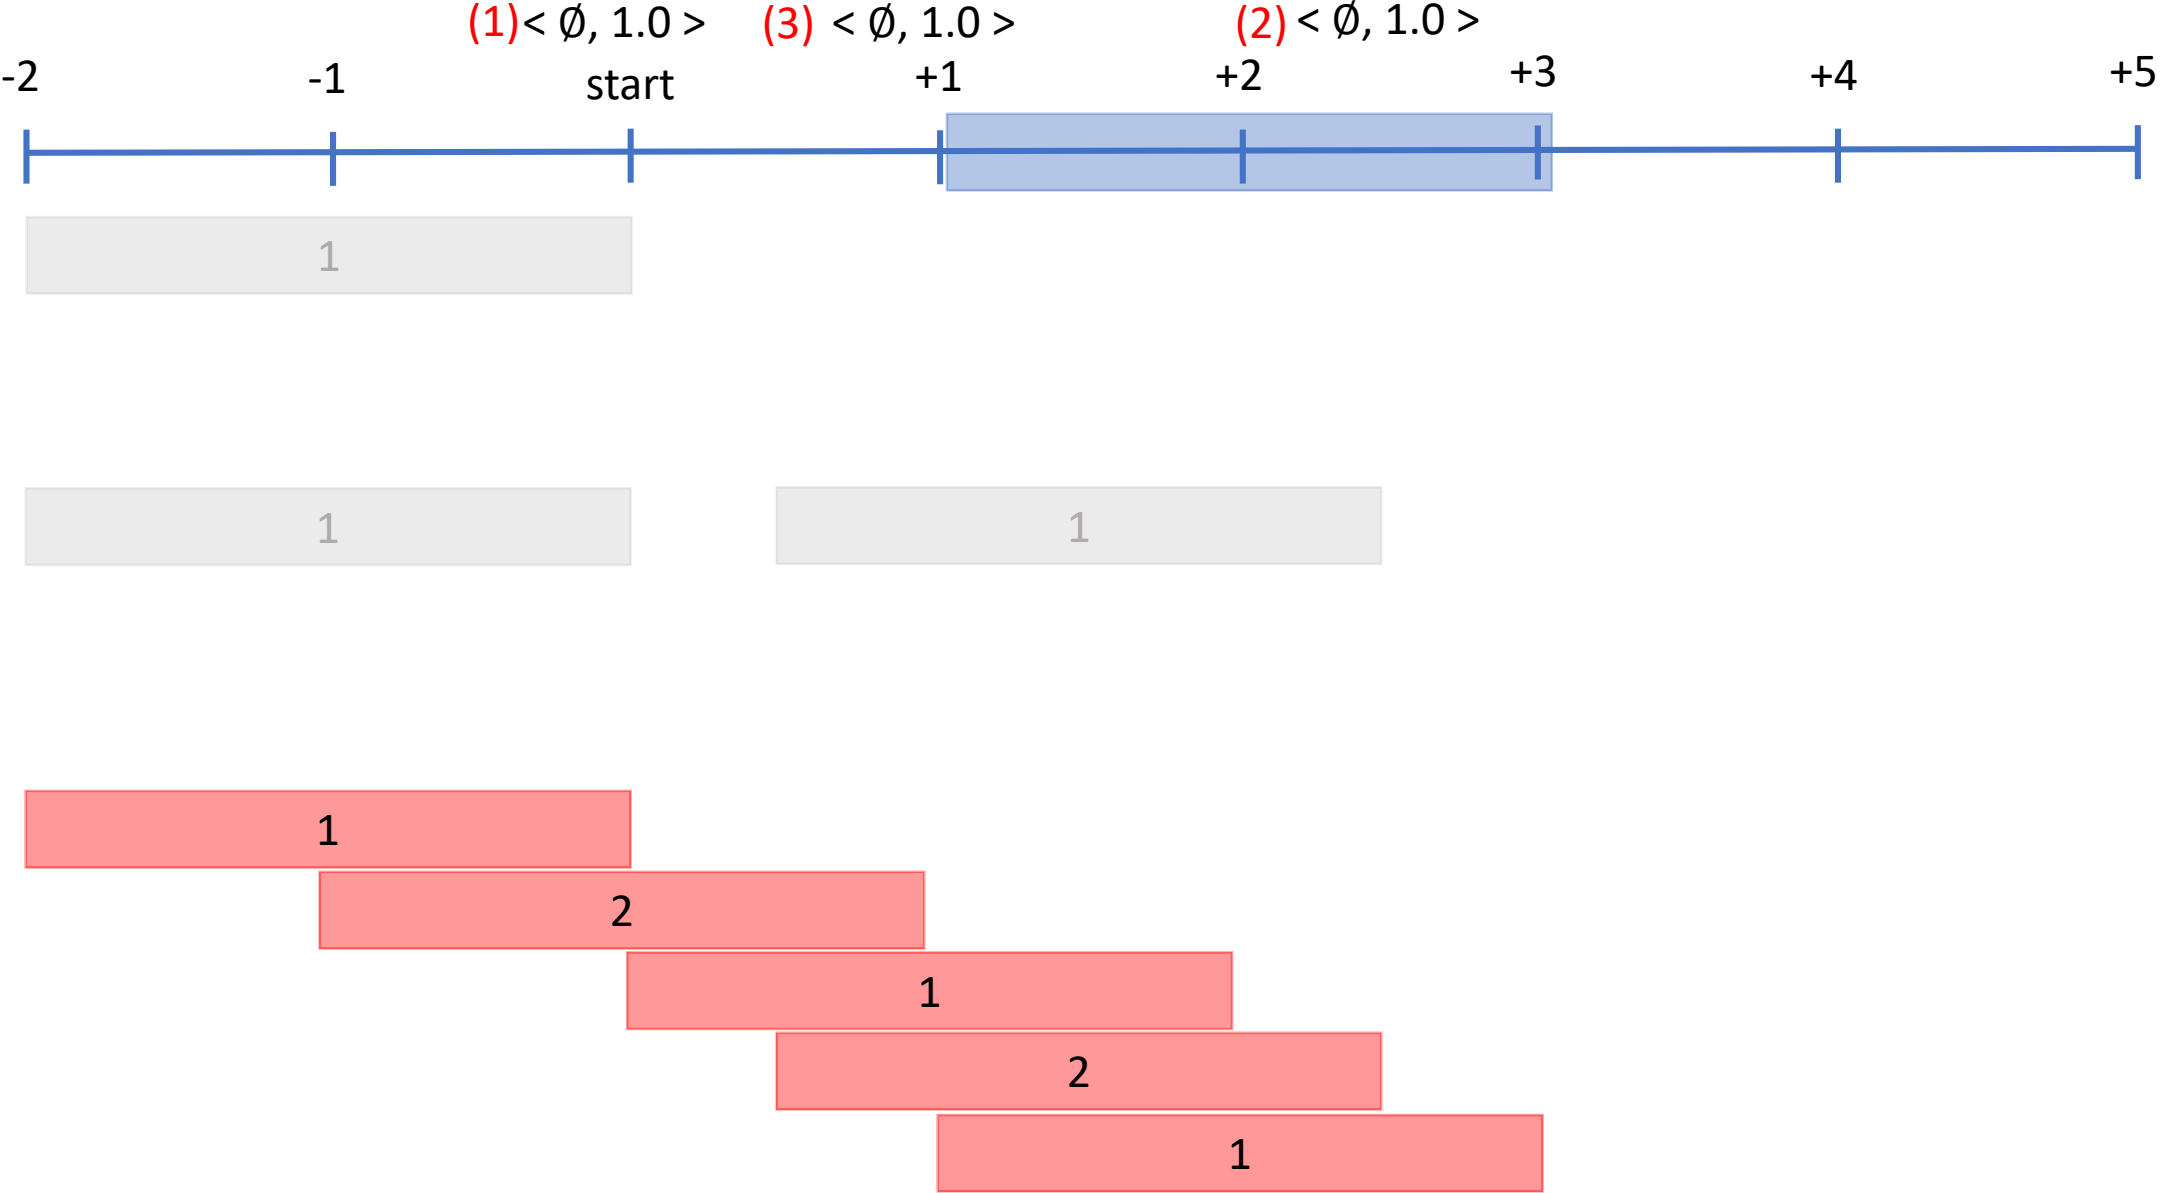
# Bonus #1: windowing – exemple jouet – Sliding window




# Bonus #1: windowing – exemple jouet – Sliding window



# Bonus #1: windowing – exemple jouet – Sliding window



# Bonus #1: windowing – exemple jouet – Sliding window



# Bonus #1: windowing - Les différents types de windowing


- Session Windows
- Hopping Windows
- Sliding Windows
- Timbling Windows

# Bonus #2: joins - Sommaire

- Un premier exemple jouet
- Les différents types de joins




# Bonus #2: joins - Un premier exemple jouet




```
public static Topology getTopology() {  
    StreamsBuilder builder = new StreamsBuilder();  
    KStream<String, String> inputAStream = builder.stream(INPUT_TOPIC_A);  
    KStream<String, String> inputBStream = builder.stream(INPUT_TOPIC_B);  
    inputAStream  
        .join(  
            inputBStream.toTable(),  
            (value1, value2) -> String.join(",", value1, value2))  
        .to(OUTPUT_TOPIC);  
    return builder.build();  
}
```

# Bonus #2: joins - Un premier exemple jouet



```
public static Topology getTopology() {  
    StreamsBuilder builder = new StreamsBuilder();  
    KStream<String, String> inputAStream = builder.stream(INPUT_TOPIC_A);  
    KStream<String, String> inputBStream = builder.stream(INPUT_TOPIC_B);  
    inputAStream  
        .join(  
            inputBStream.toTable(),  
            (value1, value2) -> String.join(",", value1, value2))  
        .to(OUTPUT_TOPIC);  
    return builder.build();  
}
```

# Bonus #2: joins - Un premier exemple jouet



```
public static Topology getTopology() {  
    StreamsBuilder builder = new StreamsBuilder();  
    KStream<String, String> inputAStream = builder.stream(INPUT_TOPIC_A);  
    KStream<String, String> inputBStream = builder.stream(INPUT_TOPIC_B);  
    inputAStream  
        .join(  
            inputBStream.toTable(),  
            (value1, value2) -> String.join(",", value1, value2))  
        .to(OUTPUT_TOPIC);  
    return builder.build();  
}
```

Conclusions ?

# Conclusions ?

- Une courbe d'apprentissage plus importante qu'anticipé ...

# Conclusions ?

- Une courbe d'apprentissage plus importante qu'anticipé ...
  - ... Mais je suis convaincu que c'est rentable

# Conclusions ?

- Une courbe d'apprentissage plus importante qu'anticipé ...
  - ... Mais je suis convaincu que c'est rentable
- L'application crée automatiquement des topics (repartition, changelog / statestore) ...

# Conclusions ?

- Une courbe d'apprentissage plus importante qu'anticipé ...
  - ... Mais je suis convaincu que c'est rentable
- L'application crée automatiquement des topics (repartition, changelog / statestore) ...
  - ... Est-ce que ça marcherait si la création automatique est désactivée (et c'est le cas de l'EventBus) ?



# Conclusions ?

- Une courbe d'apprentissage plus importante qu'anticipé ...
  - ... Mais je suis convaincu que c'est rentable
- L'application crée automatiquement des topics (repartition, changelog / statestore) ...
  - ... Est-ce que ça marcherait si la création automatique est désactivée (et c'est le cas de l'EventBus) ?
  - Next step : essayer de faire tourner l'exemple « wordcount » sur l'EventBus

# Conclusions ?

- Une courbe d'apprentissage plus importante qu'anticipé ...
  - ... Mais je suis convaincu que c'est rentable
- L'application crée automatiquement des topics (repartition, changelog / statestore) ...
  - ... Est-ce que ça marcherait si la création automatique est désactivée (et c'est le cas de l'EventBus) ?
  - Next step : essayer de faire tourner l'exemple « wordcount » sur l'EventBus
- Une ou plusieurs suite ... si le temps le permet

# Conclusions ?

- Une courbe d'apprentissage plus importante qu'anticipé ...
  - ... Mais je suis convaincu que c'est rentable
- L'application crée automatiquement des topics (repartition, changelog / statestore) ...
  - ... Est-ce que ça marcherait si la création automatique est désactivée (et c'est le cas de l'EventBus) ?
  - Next step : essayer de faire tourner l'exemple « wordcount » sur l'EventBus
- Une ou plusieurs suite ... si le temps le permet
  - Mieux présenter les différents types de windowing et de joins

# Conclusions ?

- Une courbe d'apprentissage plus importante qu'anticipé ...
  - ... Mais je suis convaincu que c'est rentable
- L'application crée automatiquement des topics (repartition, changelog / statestore) ...
  - ... Est-ce que ça marcherait si la création automatique est désactivée (et c'est le cas de l'EventBus) ?
  - Next step : essayer de faire tourner l'exemple « wordcount » sur l'EventBus
- Une ou plusieurs suite ... si le temps le permet
  - Mieux présenter les différents types de windowing et de joins
  - Des exemples plus « cas réels » (clickstreams, possibles cas ING, etc.)

# Conclusions ?

- Une courbe d'apprentissage plus importante qu'anticipé ...
  - ... Mais je suis convaincu que c'est rentable
- L'application crée automatiquement des topics (repartition, changelog / statestore) ...
  - ... Est-ce que ça marcherait si la création automatique est désactivée (et c'est le cas de l'EventBus) ?
  - Next step : essayer de faire tourner l'exemple « wordcount » sur l'EventBus
- Une ou plusieurs suite ... si le temps le permet
  - Mieux présenter les différents types de windowing et de joins
  - Des exemples plus « cas réels » (clickstreams, possibles cas ING, etc.)
  - Exemples de déploiements

# Conclusions ?

- Une courbe d'apprentissage plus importante qu'anticipé ...
  - ... Mais je suis convaincu que c'est rentable
- L'application crée automatiquement des topics (repartition, changelog / statestore) ...
  - ... Est-ce que ça marcherait si la création automatique est désactivée (et c'est le cas de l'EventBus) ?
  - Next step : essayer de faire tourner l'exemple « wordcount » sur l'EventBus
- Une ou plusieurs suite ... si le temps le permet
  - Mieux présenter les différents types de windowing et de joins
  - Des exemples plus « cas réels » (clickstreams, possibles cas ING, etc.)
  - Exemples de déploiements
  - KsqlDB -> un langage proche de SQL, surcouche à kafka-streams